Borcelle Company

Klasifikasi Citra Penyakit Daun Tanaman Padi Menggunakan CNN dengan Arsitektur VGG-19.

Eva Ristiyanti (2318016)

Latar Belakang & Masalah

Urgensi	Tantangan	Efek	Solusi
Padi merupakan elemen kunci dalam menunjang ketahanan pangan di negara ini.	Pendeteksian penyakit dengan cara manual sering kali berlangsung lambat dan tidak stabil (subjektif).	Keterlambatan dalam pengolahan menyebabkan penurunan hasil panen antara 20 hingga 30 persen.	Sistem penglihatan komputer yang dapat mengidentifikasi pola visual dari penyakit dengan cara yang objektif.

Komposisi Dataset

Sumber Citra: Dataset publik (Kaggle & UCI Machine Learning).

Objek Penelitian (Kelas Penyakit)

Bacterial Leaf Blight:

Gejala layu kekuningan pada tepi daun

Brown Spot:

Bercak cokelat berbentuk oval/bulat

Leaf Smut:

Bintik hitam kecil menyerupai jelaga.

Healthy

Citra daun padi dalam kondisi sehat (sebagai kontrol/pembanding

Tahapan Pra-Pemrosesan (Preprocessing)

- Cropping: Menghilangkan sudut citra yang tidak menggambarkan pola penyakit menggunakan Python.
- Resize: Penyeragaman ukuran menjadi 224 X 224 piksel.
- Alasan: Menyesuaikan dengan standar input arsitektur VGG-19.

Variasi Augmentasi

Volume Data: 440 citra asli dikembangkan menjadi 1.320 citra.

- Width Shift (0.2): Pergeseran gambar secara vertikal sebesar 20%.
- Height Shift (0.2): Pergeseran gambar secara horizontal sebesar 20%.
- Shear Range (0.3): Pemiringan gambar hingga membentuk jajar genjang.
- Tujuan: Memperbanyak jumlah citra guna meningkatkan akurasi model

Arsitektur VGG-19

- Total Lapisan: 19 lapisan mendalam.
- Komposisi: 16 Convolutional Layers dan 3 Fully Connected Layers.
- Fungsi Aktivasi: ReLU pada lapisan konvolusi dan Softmax pada lapisan output.
- Max Pooling: Digunakan pada setiap akhir blok konvolusi untuk mereduksi dimensi spasial.

Skenario Pengujian (192 Eksperimen)

- **Total Eksperimen: 192 kombinasi pengujian.**

Variabel yang Diuji:

- Split Data: 70:30, 80:20, dan 90:10.
- Learning Rate: 0.1, 0.01, 0.001, dan 0.0001.
- Dense Layer: 32 dan 128.
- Batch Size: 32, 64, dan 128.
- Optimizer: Adamax vs Nadam.

Rumus Evaluasi Metrik

1

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

2

$$Precission = \frac{TP}{TP+FP}$$

3

$$Recall = \frac{TP}{TP+FN}$$

4

$$F1\ Score = 2\ x\ \frac{precission\ x\ recall}{precission+recall}$$

- True Positive (TP): Penyakit terdeteksi benar sebagai penyakit tersebut.
- True Negative (TN): Daun sehat terdeteksi benar sebagai sehat.
- False Positive (FP): Daun sehat tapi model salah menebak sebagai penyakit.
- False Negative (FN): Daun sakit tapi model salah menebak sebagai sehat.

Hasil & Analisis Performa

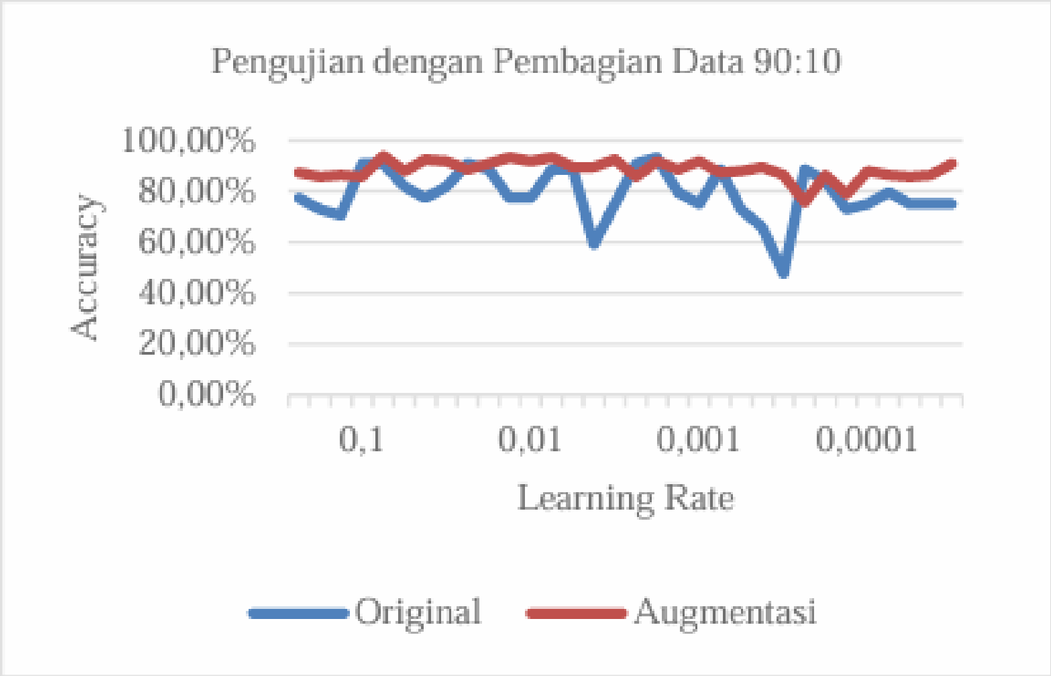

Gambar 5. Grafik Hasil Pengujian dengan Pembagian Data 90:10

Pada skenario di mana data latih sangat dominan (90%), selisih performa antara data asli dan augmentasi adalah yang terkecil

- Data Asli: Akurasi tertinggi 93,18% dicapai pada eksperimen ke-18 dengan Learning Rate (LR) 0.001, Dense 32, Batch Size 64, dan Optimizer Nadam .
- Data Augmentasi: Akurasi tertinggi 93,93% dicapai pada eksperimen ke-5 dengan LR 0.1, Dense 128, Batch Size 64, dan Optimizer Adamax .
- Kesimpulan: Augmentasi hanya meningkatkan akurasi sebesar 0,65% karena model sudah mendapatkan cukup banyak contoh dari data asli.

Hasil & Analisis Performa

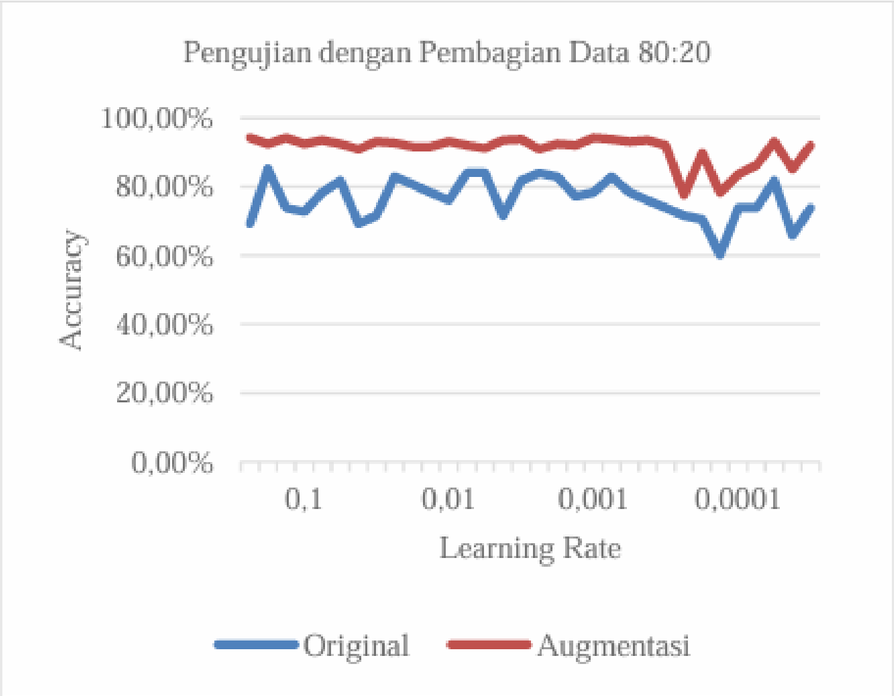

Gambar 6. Grafik Hasil Pengujian dengan Pembagian Data 80:20

Ini adalah skenario paling optimal di mana model mencapai performa puncak

- Data Asli: Akurasi tertinggi sebesar 85,22% .
- Data Augmentasi: Mencapai akurasi tertinggi di seluruh penelitian, yaitu 94,31% (Eksperimen ke-1, LR 0.1, Dense 32, Batch Size 64, Optimizer Adamax).
- Kesimpulan: Augmentasi memberikan peningkatan signifikan sebesar 9,09%.

Hasil & Analisis Performa

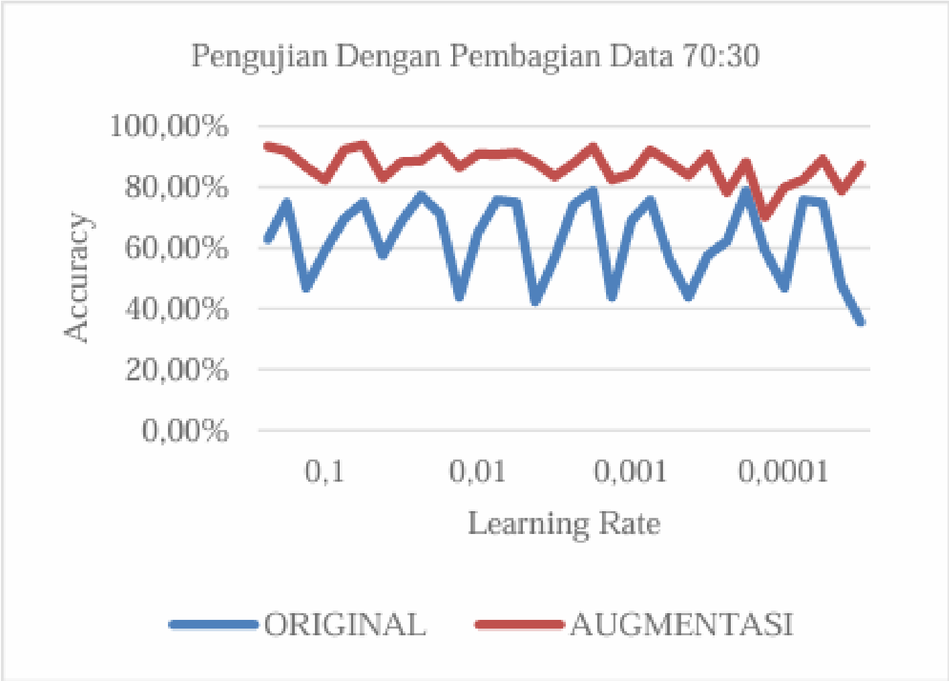

Gambar 7. Grafik Hasil Pengujian dengan Pembagian Data 70:30

Skenario ini menunjukkan kondisi di mana data latih terbatas.

- Data Asli: Performa merosot ke angka 78,78% .
- Data Augmentasi: Tetap mampu bertahan tinggi di angka 93,43% .
- Kesimpulan: Augmentasi memberikan dampak paling besar di sini dengan peningkatan akurasi 14,65%.

Analisis Stabilitas Pelatihan

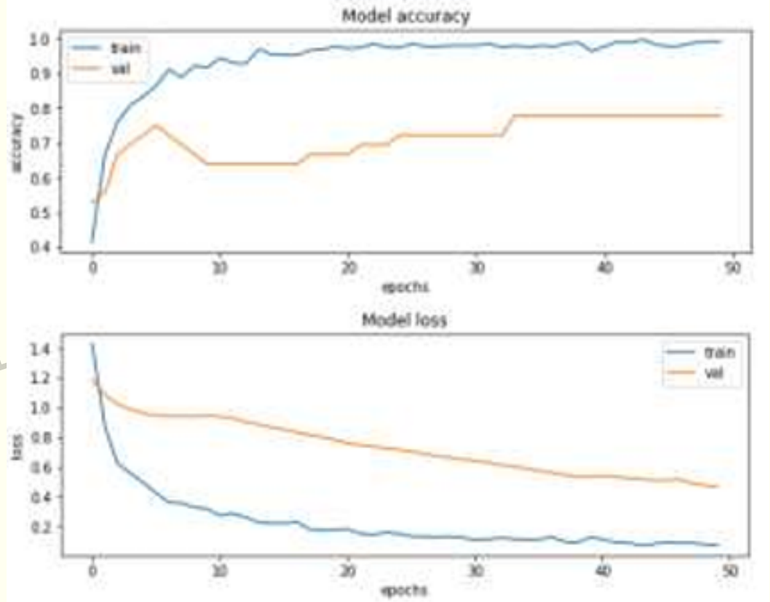

Gambar 8. Grafik Model *Accuracy* dan *Loss* pada *Training* Data Citra Asli

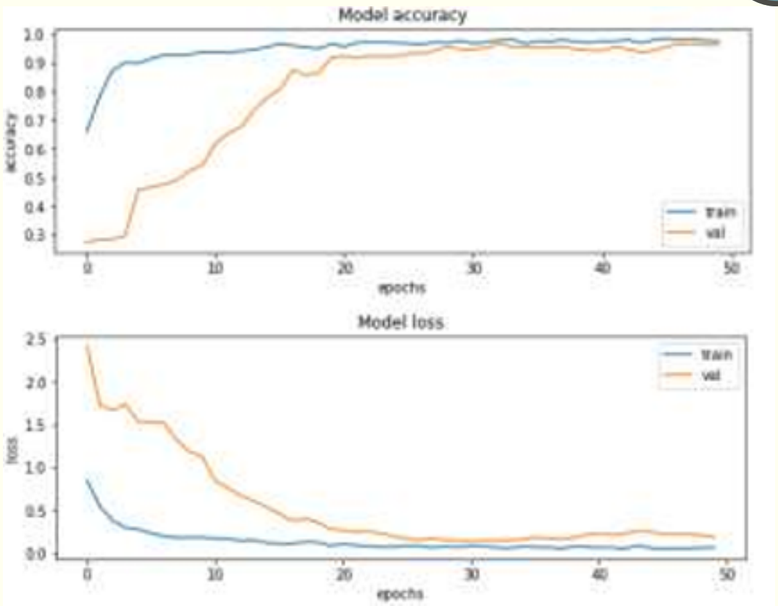

Gambar 9. Grafik Model *Accuracy* dan *Loss* pada *Training* Data Citra Augmentasi

- Model Data Asli (Gambar 8): Grafik menunjukkan kinerja yang kurang memuaskan. Akurasi maksimal hanya mencapai 0,7778 dan nilai loss masih tertahan di 0,4634 . Nilai ini dianggap tidak bagus karena akurasi tidak mendekati 1 dan loss tidak mendekati 0 .
- Model Data Augmentasi (Gambar 9): Menunjukkan performa yang sangat baik. Akurasi naik stabil hingga 0,96635 dan nilai loss turun drastis menjadi 0,1875 . Ini membuktikan model belajar secara efektif dan stabil.

Pengaruh Hyperparameter terhadap Akurasi

Berdasarkan 192 pengujian, peneliti merumuskan beberapa aturan penting terkait pengaturan parameter:

- Dense Layer: Penggunaan Dense 32 menghasilkan akurasi yang lebih tinggi dibandingkan Dense 128. Semakin kecil parameter dense, akurasi cenderung meningkat.
- Batch Size: Akurasi pada Batch Size 64 lebih tinggi daripada Batch Size 128. Semakin kecil batch size, hasil semakin presisi.
- Learning Rate: Learning Rate dengan nilai 0,1 memberikan hasil tertinggi dibandingkan nilai lainnya. Semakin besar learning rate yang digunakan (dalam rentang pengujian ini), semakin tinggi pula akurasinya.
- Optimizer:
  - Nadam memberikan hasil terbaik ketika melatih data asli.
  - Adamax memberikan hasil terbaik ketika melatih data augmentasi.

Kesimpulan

- VGG-19 efektif untuk klasifikasi citra penyakit daun padi.
- Penggunaan hyperparameter optimization (Batch size, LR, Dense) sangat memengaruhi hasil akurasi.
- Saran: Penggunaan dataset yang lebih banyak dan variasi augmentasi lain untuk penelitian selanjutnya.

Borcelle Company

TERIMAKASIH